

# Arquitectura del Pipeline de Ingesta

El pipeline de ingesta conecta las fuentes de datos con la zona de aterrizaje (*landing zone*) dentro de un **Data Lake**. Las fuentes pueden ser estructuradas (bases de datos relacionales), semiestructuradas (JSON, XML) o no estructuradas (imágenes, logs). Los métodos de carga se dividen en dos grandes categorías: **batch**, que procesa volúmenes grandes en intervalos regulares (horario, diario), y **streaming**, que ingiere eventos en tiempo real con latencia de segundos o milisegundos. Herramientas como Apache Kafka, AWS Kinesis o Google Pub/Sub son estándar para streaming; Apache NiFi, Talend o AWS Glue son comunes en pipelines batch.



## Batch (Por Lotes)


- Ejecución en intervalos: cada hora, cada día
- Ideal para datos históricos y reportes
- Menor complejidad operativa
- Herramientas: Apache Spark, AWS Glue, Talend

## Streaming (Tiempo Real)

- Procesamiento continuo de eventos
- Latencia de segundos o milisegundos
- Ideal para alertas, dashboards y fraudes
- Herramientas: Apache Kafka, Flink, Spark Streaming

# Limpieza de Datos: Flujo de Decisiones

El proceso de limpieza de datos es una secuencia de decisiones lógicas que transforma datos crudos en un conjunto confiable y analizable. Cada paso implica bifurcaciones: ¿existe el valor? ¿Es un duplicado? ¿Está dentro del rango esperado? La estrategia para manejar valores nulos depende del contexto: la **imputación** (rellenar con media, mediana o un valor constante) preserva registros pero introduce sesgo; la **eliminación** es más limpia pero reduce el volumen de datos. Los *outliers* pueden ser errores de medición o eventos reales y raros; su tratamiento requiere análisis de dominio. La corrección de tipos garantiza que fechas, números y categorías sean interpretados correctamente por los modelos.



## Valores Nulos

Identificar con `isnull()` o `IS NULL`. Imputar con media (variables numéricas), moda (categóricas) o eliminar si superan el 30% de missing.

## Duplicados

Detectar con `duplicated()` o `GROUP BY + HAVING COUNT > 1`. Conservar el registro más reciente según timestamp o eliminar todos los duplicados.

## Outliers

Usar IQR (rango intercuartílico): valores fuera de  $Q1 - 1.5 \times IQR$  o  $Q3 + 1.5 \times IQR$ . También Z-score  $> 3$ . Investigar antes de eliminar.

## Tipos de Datos

Convertir cadenas a fechas con `to_datetime()`, texto a números con `astype(int)`, y asegurar que las categorías sean `category` en pandas.

# Transformación, Normalización e Integración de Datos

Una vez limpios, los datos deben ser transformados para que los algoritmos de machine learning y las herramientas analíticas puedan procesarlos eficientemente. La **normalización y escalado** llevan las variables numéricas a rangos comparables (0-1 o media 0, desviación 1), evitando que variables con magnitudes grandes dominen el modelo. La **codificación de variables categóricas** convierte texto en representaciones numéricas: *One-Hot Encoding* crea columnas binarias por categoría, mientras que *Label Encoding* asigna enteros (útil para árboles de decisión). La **agregación** resume datos granulares (transacciones diarias) en métricas de nivel superior (resúmenes mensuales). Finalmente, la **integración** une múltiples fuentes mediante operaciones de *join* sobre claves comunes como `ID_Cliente`, enriqueciendo los registros con datos externos (clima, demografía).

## Transformación y Normalización

### Escalado Min-Max

Transforma valores al rango [0, 1]. Fórmula:  $(x - \min) / (\max - \min)$ . Ideal para redes neuronales y KNN.

### One-Hot Encoding

Convierte categorías en columnas binarias. Ej: "Color" → columnas Rojo, Verde, Azul con valores 0 o 1.

### Agregación Temporal

De transacciones diarias a resúmenes mensuales: `SUM(ventas)`, `AVG(precio)`, `COUNT(transacciones) GROUP BY mes`.

## Integración y Enriquecimiento

### Left Join

Conserva todos los registros de la tabla izquierda. Útil para enriquecer datos principales sin perder filas.

### Inner Join


Solo registros con coincidencia en ambas tablas. Elimina registros sin clave correspondiente.

### Datos Externos

Añadir variables de clima, datos demográficos o geolocalización a registros de ventas usando `ID_Cliente` o código postal como clave.

# Gobierno de Datos y Control de Calidad

El gobierno de datos garantiza que los datos preparados sean confiables, seguros y cumplan con normativas regulatorias (GDPR, HIPAA, LGPD). Es un ciclo cerrado de auditoría que opera continuamente sobre el pipeline. La **validación de reglas de negocio** asegura consistencia lógica (ej: "la edad no puede ser negativa", "la fecha de entrega no puede ser anterior a la fecha de pedido"). El **linaje de datos** (*data lineage*) rastrea el origen de cada dato, quién lo transformó y cuándo, facilitando la trazabilidad y el debugging. El **enmascaramiento de datos sensibles** anonimiza información personal (nombres, tarjetas de crédito, DNI) antes del almacenamiento o análisis. El destino final es el **Data Warehouse**, donde los datos estructurados y gobernados están listos para BI, reporting y machine learning.



## Validación de Reglas

Reglas como "edad  $\geq 0$ ", "monto  $> 0$ ", "fecha\_entrega  $\geq$  fecha\_pedido". Herramientas: Great Expectations, dbt tests, Apache Griffin.



## Linaje de Datos

Mapa completo del recorrido del dato: origen  $\rightarrow$  transformaciones  $\rightarrow$  responsables  $\rightarrow$  destino. Herramientas: Apache Atlas, DataHub, Amundsen.



## Enmascaramiento

Anonimización de PII: hashing de DNI, tokenización de tarjetas, generalización de edades. Cumplimiento GDPR, HIPAA y LGPD.



## Data Warehouse Final

Almacenamiento estructurado y optimizado para consultas analíticas. Plataformas: Snowflake, Google BigQuery, Amazon Redshift, Azure Synapse.

📄 **Conclusión del pipeline completo:** Los cinco pasos –ingesta, limpieza, transformación, integración y gobierno– forman un ciclo continuo de calidad. Un pipeline robusto no solo mueve datos, sino que garantiza que cada byte que llega al analista o al modelo sea confiable, trazable y seguro.